



INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA CATARINENSE
IFC *CAMPUS* VIDEIRA
CIÊNCIA DA COMPUTAÇÃO

MARLON VALMÓRBIDA CENDRON

TÍTULO DO TRABALHO: SUBTÍTULO (SE HOVER)

VIDEIRA

2023

MARLON VALMÓRBIDA CENDRON

TÍTULO DO TRABALHO: SUBTÍTULO (SE HOUVER)

Artigo apresentado como requisito parcial à conclusão do curso de Ciência da Computação, *Campus* Videira, Instituto Federal de Educação, Ciência e Tecnologia Catarinense.

Orientador: Prof. Dr. XXXXX.

Coorientadora: Profa. Ma. XXXXX

VIDEIRA

2023

MARLON VALMÓRBIDA CENDRON

TÍTULO DO TRABALHO: SUBTÍTULO (SE HOUVER)

Este artigo foi julgado adequado para obtenção de título de Bacharel em Ciência da Computação e aprovado em sua forma final pelo curso de Bacharelado em Ciência da Computação do Instituto Federal de Educação, Ciência e Tecnologia Catarinense – *Campus* Videira.

Aprovado em: ____/____/____.

BANCA EXAMINADORA

Prof. Dr. XXXXX (Orientador)
Instituto Federal de Educação, Ciência e Tecnologia Catarinense (IFC)

Prof. Dra. XXXXX
Instituto Federal de Educação, Ciência e Tecnologia Catarinense (IFC)

Prof. Dra. XXXXX
Instituto Federal de Educação, Ciência e Tecnologia Catarinense (IFC)

AGRADECIMENTOS

A gradecimentos.

“Inserir uma citação relacionada ao tema do trabalho, com a indicação da autoria”
(AUTOR, ano, página)

RESUMO

Apresentação concisa dos pontos relevantes do trabalho. Deve ser informativo, apresentando finalidades, metodologia, resultados e conclusões; composto de uma sequência de frases concisas, afirmativas e não de enumeração de tópicos. Deve-se usar o verbo na voz ativa e na terceira pessoa do singular, contendo de 150 a 500 palavras. Deve-se evitar símbolos que não sejam de uso corrente e fórmulas, equações, diagramas etc. que não sejam absolutamente necessários. Após o texto do resumo, recomenda-se que sejam inseridas de 3 a 5 palavras-chave.

Xxxxxxxxx xxxxxxxx xxxxxx xxxxxx xxxxxxxxxxx xxxxxxxxxxxxxxxxxxxxx. Xxxxxxxxx xxxxxxx
 xxxxxxx xxxxxxx xxxxxxx xxxxxxx xxxxxx xxxxxxx xxxxxxx xxxxxxxxxxxxxxxxxxx xxxxxxx
 xxxxxxxxxxxxxxxxxxx xxxxxxxxxxx xxx xxxxxxxxxxxxxxxxxxx xxxxxxx xxxxxxxxxxxxxxxxxxx xxxxxxxxxxx
 xxx xxxxxxxxxxxxxxxxxxx xxxxxxx xxxxxxxxxxxxxxxxxxx xxxxxxxxxxx xxx xxxxxxx xxxxxx xxxxxx
 xxxxxxx xxxxxxxxxxxxxxxxxxx. Xxxxxxxxx xxxxxxx xxxxxxx xxxxxxx xxxxxxx
 xxxxxxx xxxxxx xxxxxxx xxxxxx xxxxxx xxxxxxx xxxxxxxxxxxxxxxxxxxxxxxxx. Xxxxxxxxx
 xxxxxxx xxxxxxx xxxxxxx xxxxxxx xxxxxxx xxxxxxx. Xxxxxxxxx xxxxxx xxxxxx xxxxxxx
 xxxxxxxxxxxxxxxxxxxxxx. Xxxxxxxxx xxxxxxx xxxxxxx xxxxxxx xxxxxxx xxxxxxx
 xxxxxx. Xxxxxxxxx xxxxxx xxxxxx xxxxxxx xxxxxxxxxxxxxxxxxxxxxxxxx. Xxxxxxxxx xxxxxxx
 xxxxxxx xxxxxxx xxxxxxx xxxxxxx xxxxxxx.

Palavras-chave: Palavra 1. Palavra 2. Palavra 3. Palavra 4. Palavra 5.

[illegible]

Keywords: Palavra 1. Palavra 2. Palavra 3. Palavra 4. Palavra 5.

LISTA DE FIGURAS

LISTA DE TABELAS

LISTA DE SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
IBGE	Instituto Brasileiro de Geografia e Estatística
IFCE	Instituto Federal de Educação, Ciência e Tecnologia Catarinense
Inep	Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira
NBR	Norma Brasileira
PNS	Plano de Normalização Setorial
TCC	Trabalho de Conclusão de Curso

LISTA DE SÍMBOLOS

®	Marca registrada
α	Alfa
β	Beta
λ	Comprimento de onda
©	<i>Copyright</i>
€	Euro
%	Porcentagem

SUMÁRIO

1	INTRODUÇÃO	12
1.1	Objetivo geral	14
1.2	Objetivos específicos	15
1.3	Estrutura do trabalho	15
	REFERÊNCIAS	16

1 INTRODUÇÃO

A busca pela compreensão e reprodução das habilidades cognitivas e de aprendizado do cérebro humano tem sido um desafio constante nas áreas de neurociência computacional e Inteligência Artificial (IA). É possível argumentar que as Redes Neurais Artificiais (RNA) são o mais próximo que já chegamos dessa reprodução; entretanto, as RNAs deixaram de lado o realismo biológico em prol do aperfeiçoamento da IA (YAMAZAKI *et al.*, 2022). As Redes Neurais de Disparos (RND)¹ representam um avanço significativo em direção ao objetivo de compreender o cérebro humano, uma vez que buscam emular o comportamento das Redes Neurais Biológicas (RNB) de forma mais realista do que as abordagens tradicionais.

As RNAs convencionais são inspiradas no cérebro: neurônios disparam em determinadas frequências conforme os sinais recebidos de conexões com outros neurônios através de sinapses plásticas, cuja força muda dinamicamente de acordo com o treinamento. Entretanto, as semelhanças com o cérebro terminam aqui. As RNAs tradicionais não capturam a dinâmica interna dos neurônios biológicos, que disparam de maneiras complexas e distintas, e não apenas em uma determinada frequência. Outra diferença das RNAs com sistemas biológicos é que as RNAs possuem um período de treinamento em que as sinapses são otimizadas, e um período em que não há mais treinamento e as sinapses se tornam estáticas; enquanto nas RNBs as sinapses estão sempre se alterando conforme a experiência, salvo nos raros casos em que há um período crítico de aprendizado durante a infância que é desativado quando o indivíduo se torna adulto (CREPEL, 1982). A principal característica que torna as RNAs capazes de aprender é seu método de retropropagação de erro, um método de treinamento que até pode existir em alguns casos no cérebro (????), mas que é diferente da forma de aprendizado local por plasticidade das RNBs (YAMAZAKI *et al.*, 2022).

As RNDs são modelos muito mais próximos às RNBs que se comunicam por meio de impulsos elétricos discretos, chamados de disparos, e que aprendem por métodos realistas, como a plasticidade das sinapses. O grau de realismo biológico de uma RND depende de sua implementação, podendo empregar modelos de neurônios tão simples quanto uma única equação que descreve a mudança de tensão elétrica de um neurônio(??), ou até modelos que simulam canais de íons(HODGKIN; HUXLEY, 1952), ramificações de dendritos(PAGKALOS; CHAVLIS; POIRAZI, 2023), entre outros. As RNDs não só representam uma possível evolução das RNAs, como também são usadas para seu propósito original: compreender o cérebro através

¹ Do inglês *Spiking Neural Networks*.

da simulação ().

No entanto, treinar RNDs continua sendo uma tarefa desafiadora, já que os algoritmos de aprendizado empregados nas RNAs, além de não serem biologicamente realistas, também não são diretamente aplicáveis às RNDs devido à natureza discreta dos disparos que as torna não diferenciáveis, impedindo o cálculo de gradientes, parte fundamental no treinamento de RNAs ().

O principal método empregado para o aprendizado de RNDs é a plasticidade das sinapses. A plasticidade é a capacidade do cérebro de se adaptar e reorganizar suas conexões neurais em resposta a novas informações, experiências ou estímulos; é a principal propriedade por trás do aprendizado e da formação de memórias (). Uma das principais formas de plasticidade neural foi primeiramente descrita por (HEBB, 1949), chamada de plasticidade hebbiana, que pode resultar no fortalecimento ou enfraquecimento das sinapses com base na ativação simultânea de neurônios conectados: caso o neurônio pós-sináptico dispare logo após o neurônio pré-sináptico, significa que há uma correlação entre eles e a sinapse é fortalecida, caso contrário, a sinapse é enfraquecida.

A plasticidade hebbiana, resumida pela expressão "Neurônios que disparam juntos, conectam-se juntos", descreve a formação de conjuntos celulares² como resultado do fortalecimento das conexões entre neurônios ativados simultaneamente. Esses conjuntos podem funcionar como mecanismos de memória associativa (SAKURAI *et al.*, 2018). Tomando como exemplo a memória de uma viagem à praia: essa memória consiste em vários elementos, como o som das ondas, a sensação de areia sob os pés, o cheiro de água salgada, a visão do mar, entre outros. Cada um desses elementos sensoriais é processado em diferentes áreas do cérebro e ativa diferentes grupos de neurônios. A ativação síncrona dos neurônios responsáveis por esses elementos sensoriais leva à formação de um conjunto celular. Um tempo depois, ao sentir o cheiro do mar novamente, esse estímulo pode acabar ativando o conjunto celular, resultando na experiência da memória. Conjuntos celulares não são estruturas estáticas, essas redes dinâmicas de neurônios que surgem a partir da experiência estão sujeitas a modificações e reativações ao longo do tempo, sendo influenciadas pela falta de estímulos ou novas informações, o que pode levar à alteração ou esquecimento de partes da memória.

A plasticidade hebbiana, no entanto, não consegue gerar, por si só, conjuntos celulares estáveis quando simulada em uma RND; isso ocorre pois a atividade neural continuamente modifica as sinapses, fazendo com que em pouco tempo quaisquer estímulos não relacionados

² Do inglês *Cell Assemblies*. Também traduzido como Assembleias Celulares.

com a informação codificada no conjunto celular acabem alterando as sinapses e desfazendo o conjunto celular (GERSTNER; KISTLER, 2002).

Mas a plasticidade hebbiana não descreve toda a gama de diferentes modos com que a plasticidade se manifesta no cérebro, como é o caso das plasticidades heterossináptica, em que a ativação de neurônios causa mudanças em neurônios inativos, e homeostática, um processo lento em que as sinapses se auto-regulam para garantir estabilidade. A plasticidade também depende do tipo de neurônio, do tipo da conexão, do tempo de efeito das alterações (curto ou longo-prazo), entre outros fatores. A natureza do efeito da plasticidade também varia muito, podendo depender da frequência de disparos, da diferença de potencial, do tempo dos disparos, entre outros. Nas RNDs, assim como ocorre com os modelos de neurônios, os modelos de plasticidade também possuem uma ampla variação em termos de plausibilidade biológica. Além disso, dependendo do modelo que se deseja utilizar, pode-se combinar múltiplos modelos de plasticidade simultaneamente. Uma RND com plasticidade hebbiana junto de outras formas de plasticidade é capaz de formar conjuntos celulares estáveis por horas (ZENKE; AGNES; GERSTNER, 2015).

O sono é um processo fisiológico crucial para a consolidação³ e manutenção das memórias (BLISSITT, 2001; WALKER; STICKGOLD, 2006; DIEKELMANN; BORN, 2010). Inicialmente, postulava-se que o sono desempenhava uma função passiva no processo de consolidação da memória (JENKINS; DALLENBACH, 1924); contudo, com a descoberta das distintas fases do sono, começaram-se a explorar as contribuições ativas do sono na consolidação mnemônica (ASERINSKY; KLEITMAN, 1953). Durante o sono, ocorrem diferentes fases caracterizadas por padrões distintos de atividade cerebral: sono REM (*Rapid Eye Movement*) e sono não REM (NREM, dividido entre as fases N1, N2 e N3) (SCHULZ, 2008). Durante a fase NREM, oscilações lentas, fusos e ondulações coordenam a reativação e redistribuição de memórias dependentes do hipocampo para o neocórtex (DIEKELMANN; BORN, 2010). Já quanto ao sono REM, a dificuldade em isolar a atividade neural dessa etapa específica, que ocorre após a fase NREM, torna a discussão sobre sua contribuição para a consolidação da memória ainda controversa. Contudo, pesquisas mais recentes oferecem evidências de que o sono REM desempenha um papel fundamental na consolidação da memória espacial e contextual (BOYCE; WILLIAMS; ADAMANTIDIS, 2017).

Neste contexto, o problema abordado neste trabalho consiste em explorar a retenção de

³ A consolidação de uma memória é entendida como o processo que transforma novas memórias frágeis criadas enquanto acordado para memórias mais estáveis e de longo prazo

memórias em uma RND. A principal hipótese a ser avaliada neste trabalho é de que abordagens baseadas em simulações de fases do sono podem melhorar a estabilidade de conjuntos celulares contribuindo para o processo de retenção de memórias.

1.1 Objetivo geral

O objetivo geral deste trabalho consiste em desenvolver uma simulação realista das diferentes fases do sono em uma RND e analisar como ela pode afetar a consolidação e retenção de memórias da rede.

1.2 Objetivos específicos

Sugerir uma abordagem inspirada no sono para retenção de memórias em RND

Desenvolver uma simulação de sono inspirada nas observações de ondas cerebrais durante as diferentes fases do sono.

Avaliar a capacidade de memória da rede em relação aos padrões de imagens apresentados à ela.

Comparar a performance da RND com e sem a simulação do sono, a fim de verificar a hipótese de melhoria na capacidade de memória.

Analisar os resultados e discutir possíveis implicações e aplicações nos campos de neurociência computacional e inteligência artificial.

1 - Metodologia 2 - Depende do problema: levantamento de dados. Provavelmente fique de fora 3 - Condução de experimentos 4 - Avaliação do modelo (protocolo de avaliação) 5 - Comparação com estado da arte

1.3 Estrutura do trabalho

O trabalho está estruturado da seguinte forma: No capítulo...

REFERÊNCIAS

- ASERINSKY, E.; KLEITMAN, N. Regularly Occurring Periods of Eye Motility, and Concomitant Phenomena, During Sleep. **Science**, v. 118, n. 3062, p. 273–274, set. 1953. ISSN 0036-8075, 1095-9203.
- BLISSITT, P. A. Sleep, Memory, and Learning:. **Journal of Neuroscience Nursing**, v. 33, n. 4, p. 208–215, ago. 2001. ISSN 0888-0395.
- BOYCE, R.; WILLIAMS, S.; ADAMANTIDIS, A. REM sleep and memory. **Current Opinion in Neurobiology**, v. 44, p. 167–177, jun. 2017. ISSN 09594388.
- CREPEL, F. Regression of functional synapses in the immature mammalian cerebellum. **Trends in Neurosciences**, v. 5, p. 266–269, jan. 1982. ISSN 01662236.
- DIEKELMANN, S.; BORN, J. The memory function of sleep. **Nature Reviews Neuroscience**, v. 11, n. 2, p. 114–126, fev. 2010. ISSN 1471-003X, 1471-0048.
- GERSTNER, W.; KISTLER, W. M. **Spiking Neuron Models: Single Neurons, Populations, Plasticity**. First. [S.l.]: Cambridge University Press, 2002. ISBN 978-0-521-81384-6 978-0-521-89079-3 978-0-511-81570-6.
- HEBB, D. **The Organization of Behavior**. Zeroth. [S.l.]: Wiley & Sons New York, 1949.
- HODGKIN, A. L.; HUXLEY, A. F. A quantitative description of membrane current and its application to conduction and excitation in nerve. **The Journal of Physiology**, v. 117, n. 4, p. 500–544, ago. 1952. ISSN 0022-3751, 1469-7793.
- JENKINS, J. G.; DALLENBACH, K. M. Obliviscence during Sleep and Waking. **The American Journal of Psychology**, v. 35, n. 4, p. 605, out. 1924. ISSN 00029556.
- LILLICRAP, T. P.; SANTORO, A.; MARRIS, L.; AKERMAN, C. J.; HINTON, G. Backpropagation and the brain. **Nature Reviews Neuroscience**, v. 21, n. 6, p. 335–346, jun. 2020. ISSN 1471-003X, 1471-0048.
- PAGKALOS, M.; CHAVLIS, S.; POIRAZI, P. Introducing the Dendriify framework for incorporating dendrites to spiking neural networks. **Nature Communications**, v. 14, n. 1, p. 131, jan. 2023. ISSN 2041-1723.
- SAKURAI, Y.; OSAKO, Y.; TANISUMI, Y.; ISHIHARA, E.; HIROKAWA, J.; MANABE, H. Multiple Approaches to the Investigation of Cell Assembly in Memory Research—Present and Future. **Frontiers in Systems Neuroscience**, v. 12, p. 21, maio 2018. ISSN 1662-5137.
- SCHULZ, H. Rethinking sleep analysis. **Journal of clinical sleep medicine: JCSM: official publication of the American Academy of Sleep Medicine**, v. 4, n. 2, p. 99–103, abr. 2008. ISSN 1550-9389.
- SONG, Y.; LUKASIEWICZ, T.; XU, Z.; BOGACZ, R. Can the Brain Do Backpropagation? -Exact Implementation of Backpropagation in Predictive Coding Networks. **Advances in Neural Information Processing Systems**, v. 33, p. 22566–22579, 2020. ISSN 1049-5258.
- WALKER, M. P.; STICKGOLD, R. Sleep, Memory, and Plasticity. **Annual Review of Psychology**, v. 57, n. 1, p. 139–166, jan. 2006. ISSN 0066-4308, 1545-2085.

YAMAZAKI, K.; Vo-Ho, V.-K.; BULSARA, D.; LE, N. Spiking Neural Networks and Their Applications: A Review. **Brain Sciences**, v. 12, n. 7, p. 863, jun. 2022. ISSN 2076-3425.

ZENKE, F.; AGNES, E. J.; GERSTNER, W. Diverse synaptic plasticity mechanisms orchestrated to form and retrieve memories in spiking neural networks. **Nature Communications**, v. 6, n. 1, p. 6922, abr. 2015. ISSN 2041-1723.